

학기 1주차 세션 - GPT, Deepseek

📅 날짜	@2026년 3월 5일
🌟 상태	완료

GPT : Improving Language Understanding by Generative Pre-training

https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf

Introduction

- 모델 아키텍처에 최소한의 변경만으로 효과적인 전이를 달성하기 위해 미세 조정 중에 작업 인지 입력 변환을 사용함.
- 학습에 수동 레이블이 지정된 데이터를 필요로 하는데 이렇게 되면 레이블이 없는(주석이 부족한) 데이터로부터 언어 정보를 활용할 수 있는 모델은 시간과 비용이 많이 소요 됨.
- 기존 문제점
 - 레이블 없는 텍스트에서 단어 수준 이상의 정보 활용하는 것은 어려움
 - 1. 전이에 유용한 표현을 학습하는 데 가장 효과적인 최적화 목표가 무엇인지 불분명 함.
 - 2. 학습된 표현을 대상 작업으로 전이하는 가장 효과적인 방법에 대한 합의가 없음.
- 해결 방안
 - 비지도 사전 학습 + 지도 미세 조정 → 준지도 학습 접근법 탐구
 - 목표 : 광범위한 태스크에 적은 조정으로 전이되는 보편적인 표현을 학습하는 것
 - 훈련 절차
 - 1. 비주석 데이터를 사용하여 언어 모델링 목표를 통해 신경망 모델의 초기 매개변수를 학습함

2. 해당 지도 목표를 사용하여 매개변수를 목표 태스크에 맞게 조정함

- 모델 아키텍처 : Transformer
- 평가

1. 자연어 추론, 질의 응답, 의미론적 유사성, 텍스트 분류

관련 연구

- 자연어를 위한 준지도 학습
 - 초기 접근법 : 비주석 데이터를 사용하여 단어 수준, 구 수준 통계 계산 → 지도 모델에서 특징으로 사용됨.
 - 최근 접근법 : 비주석 데이터로부터 단어 수준 의미론 이상의 것을 학습하고 활용
 - 비주석 말뭉치 사용하여 훈련될 수 있는 구 수준, 문장 수준 임베딩 → 다양한 목표 태스크에 대한 적합한 벡터표현으로 텍스트를 인코딩하는 데에 사용됨.
- 비지도 사전학습
 - 목표 : 지도학습목표를 수정하는 대신 좋은 초기화 지점을 찾는 것
 - 초기 연구 : 이미지 분류 및 회귀 태스크에서 사용함
 - 이후 연구 : 사전학습에 정규화 기법 작용
 - 최근 연구 : 이미지 분류, 음성 인식, 개체 모호성 해소, 기계 번역
 - 언어 모델링 목표를 사용하여 신경망을 사전 학습 ⇒ 지도 학습을 통해 목표 태스크에 대해 미세 조정하는 것을 포함.
- 보조 훈련 목표
 - 준지도 학습의 대안적인 형태
 - 초기 연구 : 의미 역할 레이블링 개선 위해 품사 태깅, 청킹 등 광범위한 NLP 작업 사용
 - 최근 연구 : 대상 작업 목표에 보조 언어 모델링 목표 추가 → 시퀀스 레이블링 작업에서 성능 향상 입증함.

프레임워크

- 훈련 절차
1. 대규모 텍스트 비지도 코퍼스에서 고용량 언어 모델을 사전훈련
 2. 지도 미세 조정


- 태스크별 입력 변환
 - 순회 방식 접근법 사용 - 구조화된 입력을 사전 학습 모델이 처리할 수 있는 순서 있는 시퀀스로 변환함.
- 작업 전반에서 아키텍처에 광범위한 변경을 가하는 것을 피할 수 있게 함.
 - 텍스트 함의 : 전제 p + 구분 토큰(\$) + 가설 h 토큰 시퀀스
 - 유사성 : 비교되는 문장 간에 내재된 순서 없음.
 - 구분 토큰 + 입력 시퀀스 + 구분 토큰
 - 이 때, 두 가지 가능한 문장 순서를 모두 포함도록 수정, 각 문장을 독립적으로 처리하여 두 개의 시퀀스 표현 h_m 과 l 을 생성한 후 요소별로 더함
 - 질의응답 및 상식 추론 : 문맥 문서 + 질문 + 구분 토큰 + 가능한 답변

실험

1. 비지도 사전 학습
 - a. 데이터 셋 : BooksCorpus - 7000개 이상의 고유한 미출판 서적 포함
 - b. 모델 : 원본 트랜스포머 논문을 따름
 - c. 마스크된 셀프어텐션 헤드를 가진 12계층 디코더 전용 트랜스포머 훈련
 - d. 최대 학습률 : $2.5e-4$, Adam 최적화 방식 사용
 - e. 100에포크 훈련
 - f. 활성화 함수 : GELU
 - g. ftfy 라이브러리2, spaCy 토크나이저 3
 - h. 파인튜닝 디테일
 - i. 드롭아웃 추가 비율 : 0.1, λ : 0.5
2. 지도 미세 조정
 - a. NLI 작업 : 다섯 가지 데이터셋 평가 - 미지 캡션(SNLI), 녹음된 음성, 인기 소설 및 정부 보고서(MNLI), 위키피디아 기사(QNLI), 과학 시험(SciTail) , 뉴스 기사 (RTE) 포함한 출처
 - b. 질의응답 작업 : 중고등학교 시험의 관련 질문이 포함된 영어 지문
 - i. Story Cloze : 두 가지 옵션 중에서 다중 문장 이야기의 올바른 결말을 선택하는 것을 포함
 - c. 의미론적 유사성 (두 문장이 의미론적으로 동등한지?_

- i. 데이터셋 : Microsoft Paraphrase corpus (MRPC)(뉴스 소스에서 수집됨), Quora Question Pairs (QQP) 데이터셋, Semantic Textual Similarity benchmark (STS-B)
- d. 분류 (두 가지의 다른 텍스트 분류)
 - a. The Corpus of Linguistic Acceptability(문장이 문법적으로 올바른지) , The Stanford Sentiment Treebank(표준 이진 분류 작업)

분석



왼쪽 : 전이된 레이어 수에 따른 MultiNLI 및 RACE에서의 접근 방식 성능 → 임베딩 전이가 성능을 향상시킨다! 각 트랜스포머 레이어는 MultiNLI에서 최대 9%의 완전 전이에 대해서 이점을 보임
 오른쪽 : 지도 학습 기반의 미세 조정 없이 생성 모델을 사용하여 작업을 수행하는 휴리스틱 솔루션의 효과 - 성능이 안정적, 훈련을 거치면서 꾸준히 증가

1. 사전 학습된 모델의 각 레이어가 타겟 작업을 해결하는 데 유용한 기능을 포함
2. 생성 사전 학습이 다양한 작업 관련 기능 학습을 지원, LSTM은 제로샷 성능에서 더 높은 분산을 보이는 것을 관찰 → 트랜스포머 아키텍처의 귀납적 편향이 전이 학습을 돕는다는 것을 시사
- Ablation studies (3가지)
 1. 미세 조정 중 보조 LM 목적 함수 없이
 - 보조 목적 함수가 NLI작업, QQP에 도움이 된다는 것을 관찰
 2. 동일한 프레임워크를 사용하여 단일 계층 LSTM과 비교하여 트랜스포머의 효과 분석
 - 트랜스포머 대신 LSTM을 사용했을 때 평균 5.6점의 점수 하락
 3. 사전 학습 없이 지도 학습만

→ 전체 모델 대비 성능 14.8% 감소

결론

- GPT는 **대규모 비주석 텍스트로 사전학습** → **태스크별 지도 미세조정**이라는 2단계 준지도 학습 프레임워크를 통해 자연어 추론·질의응답·의미 유사성·텍스트 분류 등 NLP 태스크에서 기존 모델을 능가하는 성능을 달성함
- Transformer 디코더 기반 아키텍처가 LSTM 대비 전이 학습에 더 유리한 귀납적 편향을 제공하며, 사전학습된 각 레이어가 타겟 태스크에 유용한 표현을 담고 있음을 ablation study를 통해 입증
- 보조 언어 모델링 목표와 태스크 인지 입력 변환을 통해 아키텍처 수정을 최소화하면서도 폭넓은 일반화가 가능함을 보임.

한 줄 요약

- 레이블 없는 대규모 텍스트로 Transformer를 사전학습시킨 뒤 최소한의 미세조정만으로 다양한 NLP 태스크를 잘 풀 수 있음.

인사이트

- 가장 인상 깊었던 건 태스크별로 아키텍처를 새로 설계하지 않고 입력 변환만으로 전혀 다른 태스크들을 하나의 모델로 처리했다는 점이다. 이것이 가능한 이유가 사전학습을 먼저 거쳐서 언어 자체를 충분히 이해했기 때문이라는 것도 흥미로웠다. 지금은 GPT가 널리 쓰여 당연해보이지만, 처음 이 논문이 나왔을 당시에는 당연하지 않았을 발상이라는 점에서 영향력이 느껴졌다.

DeepSeek-R1

<https://arxiv.org/pdf/2501.12948>

어떤 문제를 해결하려 했는가?

- LLM의 추론 능력이 **인간이 레이블링한 데이터에 과도하게 의존**한다는 문제. **순수 강화 학습만으로** 인간 레이블 없이 추론 능력을 키울 수 있는지를 보여주려 했음.

연구 동기와 문제점

- Chain-of-Thought 같은 기법들이 성과를 냈지만, 여전히 **대규모 인간 주석 데이터**에 의존
 - 복잡한 문제일수록 모델 능력이 부족
 - 핵심 질문 : 인간 개입 없이도 모델 스스로 추론 패턴을 발견할 수 있을까?
-

관련 연구 (Related Works)

- OpenAI o1처럼 추론 특화 모델들이 등장하며 **thinking 과정**을 명시적으로 모델링하는 흐름
 - Process Reward Model, MCTS 등 추론 강화 기법들이 연구되었으나 확장성과 비용 문제 존재
 - RL 기반 LLM 학습은 있었지만 추론에 특화된 시도는 부족했음
-

연구 접근법과 모델 구조

- **DeepSeek-R1-Zero** : 사전학습 모델에 SFT 없이 순수 RL만 적용 → 추론 패턴 자연 발생 확인
 - **DeepSeek-R1** : 소량의 cold-start 데이터로 SFT 먼저 → 이후 RL 적용 → 가독성·성능 모두 향상
 - 보상 설계 : 정답 정확도 + 포맷 준수 (별도 reward 모델 없이 rule-based)
 - 소형 모델(1.5B~70B)로의 **증류**도 수행
-

실험 구성과 결과 (Experiments)

- 수학, 코딩, 과학, 논리 추론 벤치마크에서 평가
 - OpenAI o1과 비슷하거나 일부 능가하는 성능
 - 증류된 소형 모델도 기존 오픈소스 모델 대비 압도적 성능
-

발견과 한계점

발견

- RL만으로도 self-reflection, verification 같은 고급 추론 패턴이 **자연스럽게 창발**
- Cold-start 데이터가 있으면 가독성과 성능이 크게 향상됨

한계

- 언어 혼용 문제 (영어/중국어 섞임)

- 일반 대화, 롤플레이 등 추론 외 태스크는 상대적으로 약함
 - 긴 컨텍스트에서의 소프트웨어 엔지니어링 성능은 아직 부족
-

결론

순수 RL로 추론 능력을 획득할 수 있음을 증명했고, 증류를 통해 소형 모델에도 이를 전파할 수 있음을 보임. 오픈소스로 공개하여 커뮤니티 기여

인사이트

GPT가 무엇을 알고 있는지(표현)를 학습했고 DeepSeek-R1은 어떻게 생각하는지(추론 과정)를 학습한다는 것을 논문을 읽으면서 알게 되었다. 사전학습으로 언어를 이해시키려던 패러다임에서 강화학습만으로 모델이 스스로 추론 방법을 찾아내는 패러다임으로 넘어간 중요한 논문이라고 느꼈다.