

# 학기 3주차 세션 : GAN & Diffusion

|      |               |
|------|---------------|
| 📅 날짜 | @2026년 3월 19일 |
| 🌟 상태 | 완료            |

## 1. GAN

arxiv.org

<https://arxiv.org/pdf/1406.2661>

- 데이터 분포를 포착하는 생성 모델 G와 샘플이 G에서 생성한 것이 아닌 훈련 데이터에서 왔을 확률을 추정하는 판별 모델 D를 동시에 훈련시킴.

## 0. 서론


- 기존 딥 생성 모델의 한계
  - 초대 가능도 추정 및 관련 전략에서 발생하는 많은 추적 불가능한 확률 계산을 근사하는 어려움
  - 생성 맥락에서 조각별 선형 유닛의 이점을 활용하는 어려움
- 제안: **GAN**
  - 적대적 생성 모델  $\Rightarrow$  모델 분포 또는 데이터 분포에서 온 샘플인지 여부를 결정하도록 학습하는 판별 모델과 대립함.
  - adversarial nets  $\rightarrow$  backpropagation, dropout 알고리즘만을 사용하여 생성 모델, 판별 모델 모두 훈련, 순방향 전파만을 사용하여 생성 모델로부터 샘플링
  - 근사 추론, 마르코프 연쇄는 필요없음!

## 1. 관련 연구

- Deep belief networks, DBNS : 단일 비방향성 계층과 여러 방향성 계층을 포함하는 하이브리드 모델
  - 계산상의 어려움 수반

- GSN(생성 확률적 네트워크) : 확률 분포를 명시적으로 정의  $X \rightarrow$  원하는 분포로부터 샘플을 추출하는 생성 기계를 훈련함. 이때 역전파로 훈련되도록 설계되는 장점이 있음.
  - adversarial nets와 다른점은 마르코프연쇄가 필요함.


## 2. Adversarial nets



- 모델이 멀티레이어 퍼셉트론
  - **구조**: 생성자(G)는 랜덤 노이즈  $\rightarrow$  가짜 데이터를 만들고 판별자(D)는 진짜/가짜를 구분하는 두 신경망이 대결하는 구조
  - **목표**: D는 진짜를 진짜로, 가짜를 가짜로 잘 맞히려 하고 G는 D를 속이려 하는 **minimax 게임**
  - **학습 방법**: D를 k번 업데이트  $\rightarrow$  G를 1번 업데이트를 반복 (D가 항상 G보다 약간 앞서 있게 유지함.)
  - **초기 학습 문제**: G가 미숙할 때  $\log(1-D(G(z)))$  최소화는 기울기가 너무 작아 학습이 안 되므로, 대신  $\log D(G(z))$  **최대화**로 바뀌어서 기울기를 확보
  - **이론적 보장**: G와 D의 용량이 충분하면 결국 G가 실제 데이터 분포를 완벽히 복원하는 균형점에 수렴함

## 3. 실험 & 결과

- 훈련에 활용한 데이터셋 : MNIST, Toronto Face Database, CIFAR-10을 포함
- 생성자(G) 신경망 : ReLU 활성화 함수 + 시그모이드
- 판별자(D) 신경망 : maxout 활성화 함수
- 판별자 신경망 훈련에는 Dropout 적용



우측 노란색 열이 모델이 직접 생성한 결과물 → a) MNIST b) TFD(Toronto Face Database), c) CIFAR-10 (fully connected model), d) CIFAR-10 (convolutional discriminator and "deconvolutional" generator)

- 실험 결과, 모델이 훈련데이터를 단순히 암기한 것이 아니라 새로운 샘플을 생성했음을 실제 샘플들과 유사하지만 완전히 똑같지는 않다는 것을 보면 알 수 있음.
- 생성 과정이 마르코프 연쇄 혼합에 의존하지 않기 때문에 생성된 샘플들은 서로 상관관계가 없음을 알 수 있음.

## 4. 결론 및 한계점

- 한계점
  - D와 G가 잘 동기화 되어야 함. ⇒ D를 업데이트하지 않고 G만 너무 많이 훈련하면 안됨
- 장점
  - 마르코프 체인이 전혀 필요없음 ⇒ 오직 역전파만 사용함.
  - 학습 중에 추론이 필요없음.
  - 매우 날카롭거나 심지어 퇴화된 분포도 표현할 수 있음.

## 5. 향후 연구 방향

- 조건부 생성 모델
  - 입력  $c$ 를 생성자(G)와 판별자(D) 모두의 입력으로 추가하여 조건부 생성 모델  $p(x | c)$ 를 만들 수 있음.
- 학습된 근사 추론
  - $z$ 를 주어진  $x$ 로 예측하는 보조 네트워크를 훈련시켜 학습된 근사 추론을 수행할 수 있음. 생성자 네트워크가 훈련을 마친 후 고정된 생성자 네트워크에 대해 추론 네트워크를 훈련할 수 있다는 장점을 가지고 있음.
- 부분 조건부 모델링
  - 파라미터를 공유하는 조건부 모델들을 훈련시켜  $x$ 의 인덱스 집합  $S$ 의 부분집합에 대한 모든 조건부  $p(x_S | x_{-S})$ 를 근사적으로 모델링할 수 있음.
- 준지도 학습: 판별자나 추론 네트워크의 특징을 사용하여 제한된 레이블 데이터가 있을 때 분류기의 성능을 향상시킬 수 있음.
- 효율성 개선: G와 D를 조정하거나 훈련 중에  $z$ 를 샘플링할 분포를 결정하는 더 나은 방법을 고안하여 훈련을 크게 가속화 가능.

## 인사이트

GAN의 핵심 아이디어인 Generator와 Discriminator의 적대적 학습 구조는 개념적으로는 이미 알고 있었다. 하지만 논문을 통해 수식과 실험 결과를 직접 본 후, 한계점에 대해 진지하게 생각해보게 됐다.

특히 흥미로웠던 부분은 학습 안정성 문제다. G와 D가 서로 균형 있게 성장해야하는데 한 쪽이라도 너무 앞서나가면 전체 학습이 무너진다. D가 너무 강해지면 G의 gradient가 소실되고 G가 너무 빠르면 D가 제대로 된 신호를 주지 못한다. 개념만 알 때는 "두 모델이 경쟁한다"는 것으로만 알고 있었는데 이런 균형 문제가 GAN의 고질적인 난제라는 걸 논문을 통해 처음 실감했다.

## 2. Diffusion

arxiv.org

<https://arxiv.org/pdf/2006.11239>

- 확산 확률 모델

- 정해져있는 시간 후에 데이터와 일치하는 샘플을 생성하기 위해 변분 추론을 사용하여 훈련된 매개변수화된 마르코프 연쇄
- 연쇄의 전이
  - 신호가 파괴될 때까지 샘플링의 반대 방향으로 점진적으로 데이터에 노이즈를 추가
- 기존 한계
  - 고품질 샘플 생성 시연이 없었음.
- 의의
  - 확산 모델이 실제로 고품질 샘플 생성할 수 있음.
  - 다른 유형의 생성 모델에 대한 결과보다 더 나은 성능
  - 확산 모델의 특정 매개변수화가 훈련 중 다중 노이즈 레벨에서의 디노이징 스코어 매칭 및 샘플링 중에는 애널드 랭글리 다이내믹스와의 동등성을 드러냄

## 0.

- 확산모델, DDPM 정리

### 1. 전체 구조

확산 모델은 두 가지 과정으로 구성됩니다.

**순방향 과정 (Forward)** — 데이터에 노이즈를 점진적으로 추가

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$$

**역방향 과정 (Reverse)** — 노이즈에서 데이터를 복원

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

### 2. 임의 타임스텝 직접 샘플링

$\alpha^-t = \prod s = 1t\alpha s$ 로 정의하면, 중간 단계를 거치지 않고 한 번에 샘플링 가능

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

### 3. 학습 목표

변분 하한을 분해하면

$$L = L_T + \sum_{t>1} L_{t-1} + L_0$$

- $L_T$ : 상수 (무시)
- $L_{t-1}$ :  $q(x_{t-1} | x_t, x_0)$ 와  $p_\theta(x_{t-1} | x_t)$  사이의 **KL divergence**
- $L_0$ : 이산 디코더 항

#### 4. 핵심 파라미터화: $\epsilon$ 예측

$\mu_\theta$ 가 평균을 직접 예측하는 대신,  
노이즈  $\epsilon$ 을 예측하도록 재파라미터화

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left( x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right)$$

#### 5. 최종 단순화 목적함수

가중치를 제거한 실용적인 학습 손실

$$L_{\text{simple}}(\theta) = \mathbb{E}_{t, x_0, \epsilon} \left[ \left\| \epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2 \right]$$

#### 핵심 포인트

"노이즈를 섞은 이미지를 넣으면 섞인 노이즈  $\epsilon$ 을 예측해라"  
이 단순한 MSE 손실만으로 고품질 이미지 생성이 가능

#### 6. 샘플링 (역과정)

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z, \quad z \sim \mathcal{N}(0, I)$$

## 1. 실험

- 모든 실험에서  $T = 1000$
- $\beta_t$ 는  $\beta_1=10^{-4}$ 에서  $\beta_T=0.02$ 로 선형적으로 증가
- 신경망: group normalization을 사용하는 U-Net backbone
- $16 \times 16$  feature map  $\Rightarrow$  self-attention 사용



Figure 3: LSUN Church samples. FID=7.89




Figure 4: LSUN Bedroom samples. FID=4.90

Table 1: CIFAR10 results. NLL measured in bits/dim.

| Model                                        | IS              | FID         | NLL Test (Train)   |
|----------------------------------------------|-----------------|-------------|--------------------|
| <b>Conditional</b>                           |                 |             |                    |
| EBM [11]                                     | 8.30            | 37.9        |                    |
| JEM [17]                                     | 8.76            | 38.4        |                    |
| BigGAN [3]                                   | 9.22            | 14.73       |                    |
| StyleGAN2 + ADA (v1) [29]                    | <b>10.06</b>    | <b>2.67</b> |                    |
| <b>Unconditional</b>                         |                 |             |                    |
| Diffusion (original) [53]                    |                 |             | $\leq 5.40$        |
| Gated PixelCNN [59]                          | 4.60            | 65.93       | 3.03 (2.90)        |
| Sparse Transformer [7]                       |                 |             | <b>2.80</b>        |
| PixellIQN [43]                               | 5.29            | 49.46       |                    |
| EBM [11]                                     | 6.78            | 38.2        |                    |
| NCSNv2 [56]                                  |                 | 31.75       |                    |
| NCSN [55]                                    | $8.87 \pm 0.12$ | 25.32       |                    |
| SNGAN [39]                                   | $8.22 \pm 0.05$ | 21.7        |                    |
| SNGAN-DDLS [4]                               | $9.09 \pm 0.10$ | 15.42       |                    |
| StyleGAN2 + ADA (v1) [29]                    | $9.74 \pm 0.05$ | 3.26        |                    |
| Ours ( $L$ , fixed isotropic $\Sigma$ )      | $7.67 \pm 0.13$ | 13.51       | $\leq 3.70$ (3.69) |
| <b>Ours (<math>L_{\text{simple}}</math>)</b> | $9.46 \pm 0.11$ | <b>3.17</b> | $\leq 3.75$ (3.72) |

## 2. 결론

- 확산 모델을 사용하여 고품질 이미지 샘플을 제시함
- 확산 모델과 마르코프 연쇄 학습을 위한 변분 추론, 노이즈 제거 스코어 매칭 및 균질화 랑주뱅 동역학(확장하여 에너지 기반 모델 포함), 자기회귀 모델, 점진적 손실 압축 간의 연관성 발견

## 인사이트

Diffusion 모델은 현재 CV를 넘어 VLM과 NLP 전반으로 빠르게 확장되고 있는 기법이다. 이미지 생성에서 출발했지만 **멀티모달 모델**에서도 핵심으로 사용되고있고 최근에는 텍스트 자체를 diffusion 방식으로 생성하려는 것을 알고 있었는데 논문을 읽으니 큰 틀이 명확하게 이해되었다.

학습 원리 자체도 직관적이다. 데이터에 노이즈를 점진적으로 추가한 뒤에 이것을 다시 되돌리는 과정을 학습하는 구조는 망가지는 방법을 알면 다시 복구하는 방법도 안다라는 단순한 아이디어에서 출발한 것이 놀랍다. 이 전에 읽었던 GAN처럼 두 모델의 균형을 맞추는 필요 없이 **단일 모델로 안정적으로 학습**된다는 점에서 GAN이 갖는 학습 불안정성 문제를 구조적으로 해소한 접근이라고 느꼈다.