

학기 4주차 세션 : CLIP & SAM

📅 날짜	@2026년 3월 26일
☀️ 상태	완료

1. CLIP

"Learning Transferable Visual Models From Natural Language Supervision"

Radford et al., OpenAI — ICML 2021

arxiv.org

<https://arxiv.org/pdf/2103.00020>

1. Abstract — 어떤 문제를 해결하려 했는가?

- 기존 SOTA CV 시스템들은 미리 정해진 고정된 카테고리만을 예측하도록 학습됨.
 - 이런 제한적 지도 방식은 새로운 시각적 개념을 지정하려면 추가적인 레이블 데이터가 필요하기 때문에 일반성과 실용성을 크게 떨어뜨림.
- **CLIP**은 인터넷에서 수집한 4억 개의 (이미지, 텍스트) 쌍으로 사전학습하여 자연어로 시각 개념을 참조하고 zero-shot으로 다양한 downstream task에 적용할 수 있음을 보임.

2. Introduction — 연구 동기와 문제점

NLP와 Computer Vision의 격차

- NLP에서는 raw text로부터 직접 학습하는 사전학습 방법들이 지난 몇 년간 혁명적인 발전을 이뤄왔음
- GPT-3 같은 시스템은 데이터셋 특화 학습 없이도 많은 태스크에서 경쟁력 있는 성능을 보임.
 - 그러나 컴퓨터 비전에서는 여전히 ImageNet처럼 사람이 직접 레이블링한 데이터셋으로 사전학습하는 것이 표준.

핵심 질문: "웹 텍스트로부터 직접 학습하는 스케일러블한 사전학습 방법이 컴퓨터 비전에서도 동일한 돌파구를 만들 수 있을까?"

3. Related Works — 관련 연구 동향

- Zero-data learning의 아이디어는 10년 이상 전으로 거슬러 올라가지만, 최근까지는 주로 보지 못한 객체 카테고리를 일반화하는 방식으로 연구되어 옴.

주요 선행 연구들

- **Visual N-Grams (Li et al., 2017)**: Flickr 3천만 장으로 학습, ImageNet zero-shot 11.5% 달성 — CLIP의 가장 직접적인 선행 연구
- **VirTex**: Transformer 기반 자기회귀 언어 모델링
- **ICMLM**: 마스크 언어 모델링을 이미지 표현 학습에 적용
- **ConVIRT**: CLIP과 동일한 대조 학습 목표를 의료 영상 분야에 적용한 연구

그러나 이 모델들은 여전히 Big Transfer나 weakly supervised ResNeXt 같은 SOTA 모델에 미치지 못함.

→ 결정적인 차이는 **스케일**

4. Method — 연구 접근법과 모델 구조

4-1. 데이터셋 구축 (WIT)

기존에 주로 사용되던 MS-COCO, Visual Genome은 각각 약 10만 장으로 현대 기준으로 너무 작음

→ 이를 극복하기 위해 인터넷의 다양한 공개 출처에서 수집한 **4억 개의 (이미지, 텍스트) 쌍**으로 새로운 데이터셋 WIT(WebImageText)를 구축했고 500,000개의 쿼리를 사용해 최대한 광범위한 시각 개념을 커버하도록 함.

4-2. 효율적인 사전학습 방법 선택

초기 접근법은 이미지 CNN과 텍스트 Transformer를 함께 학습시켜 캡션을 예측하는 것.

→ 하지만 모델이 이미지마다 정확한 단어를 예측하려다 보니 각 이미지에 다양한 설명이 가능해 계산량이 매우 많아지는 문제 발생

해결책

- **Contrastive Learning**으로 전환

4-3. 모델 구조

구성요소	세부 사항
이미지 인코더	ResNet-50/101/50×4/50×16/50×64 또는 ViT-B/32, ViT-B/16, ViT-L/14

구성요소	세부 사항
텍스트 인코더	12-layer, 512-wide Transformer (8 attention heads)
임베딩 공간	두 인코더의 출력을 선형 투영으로 공통 멀티모달 임베딩 공간으로 매핑

4-4. Zero-shot 추론 방식

테스트 시, "A photo of a {class name}." 형태의 프롬프트 템플릿으로 각 클래스 텍스트를 인코딩 → 이미지와 가장 유사한 텍스트를 분류 결과로 사용

5. Experiments — 실험 구성과 결과

실험 범위

- 30개 이상의 기존 컴퓨터 비전 데이터셋 (OCR, 행동 인식, 지리 위치, 세분화 분류 등)

주요 결과

- ImageNet 학습 데이터를 단 한 장도 사용하지 않고도 ImageNet에서 완전 학습된 ResNet-50과 동등한 76.2% 정확도를 달성함.
- Zero-shot CLIP은 분포 이동(distribution shift)에 대해 ResNet-101보다 훨씬 강건함. ResNet-101이 ImageNet에서는 비슷한 성능을 보이지만 다른 데이터셋에서는 크게 떨어지는 반면, CLIP은 다양한 데이터셋에서도 일관된 성능을 유지.

6. Discussion — 무엇을 발견했고 한계점은?

주요 발견

- Zero-shot CLIP이 fully supervised 모델에 비해 분포 이동에 훨씬 강건함
- 자연어 감독만으로도 다양한 시각 태스크를 학습 가능
- 프롬프트 엔지니어링(템플릿 앙상블)이 성능에 큰 영향을 미침

한계점

- EuroSAT(위성 이미지), MNIST(숫자 인식), KITTI Distance(거리 추정) 등 특수 도메인 데이터셋에서는 zero-shot 성능이 크게 떨어지는 것을 볼 수 있음. → 학습 분포에 없는 추상적/전문적 개념에 약함
- 학습 데이터의 사회적 편향이 모델에 그대로 반영될 수 있음
- 여전히 fine-tuning된 task-specific 모델보다 성능이 낮은 경우 존재

7. Conclusion — 결론 및 주요 요약

- 자연어 감독을 활용한 대규모 contrastive 사전학습은 효율적이고 스케일러블한 방법
 - zero-shot 방식으로도 기존 fully supervised 모델에 준하는 성능을 달성
- CLIP은 30개 이상의 다양한 데이터셋에서 강건한 전이 성능을 보이며, 코드와 모델 가중치를 공개해 후속 연구의 기반을 제공함.

8. 핵심 아이디어

"이미지와 텍스트를 같은 공간에 정렬시키면, 텍스트만으로 어떤 개념이든 zero-shot으로 인식할 수 있다"

2. SAM (Segment Anything)

Kirillov et al., Meta AI Research (FAIR) — ICCV 2023

arxiv.org

<https://arxiv.org/pdf/2304.02643>

1. Abstract — 어떤 문제를 해결하려 했는가?

- 이미지 세그멘테이션을 위한 새로운 태스크, 모델, 데이터셋을 동시에 제안함.
- 효율적인 모델을 데이터 수집 루프에 활용하여 역사상 가장 큰 세그멘테이션 데이터셋을 구축했으며 1,100만 장의 이미지에 10억 개 이상의 마스크가 포함되어 있음

"세그멘테이션 분야에도 NLP의 foundation model처럼 어떤 객체든 프롬프트 하나로 분할하는 범용 모델을 만들 수 있을까?"

2. Introduction — 연구 동기와 문제점

1. NLP foundation model에서 영감

- 웹 규모 데이터로 사전학습된 대형 언어 모델들이 강력한 zero-shot/few-shot 일반화 능력으로 NLP를 혁신하고 있음
- foundation model들은 프롬프트 엔지니어링을 통해 학습 당시에 없던 태스크와 데이터 분포까지 일반화할 수 있음.

2. 컴퓨터 비전의 문제

- 비전 분야에서도 CLIP, ALIGN 같은 foundation model이 탐구되고 있지만 컴퓨터 비전에서는 풍부한 학습 데이터가 존재하지 않아 문제가 발생함.
 - 특히 세그멘테이션 마스크는 인터넷만으로는 풍부하지 않기 때문에 대안이 필요함.

세 가지 핵심 질문

- (1) zero-shot 일반화를 가능하게 할 태스크는 무엇인가?
- (2) 그에 맞는 모델 구조는 어떻게 되는가?
- (3) 이 태스크와 모델을 지원할 데이터는 어떻게 확보할 것인가?

3. Related Works — 관련 연구 동향

인터랙티브 세그멘테이션, 엣지 검출, 슈퍼픽셀, 객체 후보 생성, 전경 세그멘테이션, 시맨틱 세그멘테이션, 인스턴스 세그멘테이션, 파노프틱 세그멘테이션 등이 존재함.

기존 연구들과의 차별화

- **기존 멀티태스크 시스템:** 학습 시 정해진 고정 태스크들만 수행 가능
- **기존 인터랙티브 세그멘테이션:** 사람 사용자를 전제로 설계, 충분한 입력 후 유효 마스크 예측이 목표
- **SAM:** 어떤 프롬프트에도 즉시 유효한 마스크를 예측, 더 큰 시스템의 컴포넌트로도 동작 가능

주요 선행 연구

- CLIP/ALIGN (비전-언어 정렬), DALL-E (이미지 생성), GPT-3 (NLP foundation model)

4. Method — 연구 접근법과 모델 구조

4-1. Promptable Segmentation Task (새 태스크 정의)

- 프롬프트는 이미지에서 무엇을 분할할지 지정하는 것으로 전경/배경 포인트 집합, 대략적인 박스나 마스크, 자유형 텍스트, 또는 분할 대상을 나타내는 어떤 정보든 포함할 수 있음.
- **Ambiguity 처리**
 - 애매한 프롬프트(예: 셔츠 위의 점 → 셔츠인지 사람인지 불분명)에도 최소한 하나의 객체에 대해 합리적인 마스크를 출력해야 함

4-2. SAM 모델 구조 (3가지 컴포넌트)

컴포넌트	상세
Image Encoder	MAE 사전학습된 ViT(Vision Transformer), 이미지당 1회 실행, 고해상도 입력 처리
Prompt Encoder	포인트·박스 → 위치 인코딩 + 학습된 임베딩 / 텍스트 → CLIP의 텍스트 인코더 / 마스크 → 컨볼루션 후 이미지 임베딩과 합산
Mask Decoder	Transformer 디코더 블록 변형, 프롬프트-이미지 간 양방향 cross-attention, 최종적으로 마스크 예측

4-3. Data Engine (3단계)

세그멘테이션 마스크는 인터넷에서 자연적으로 수집이 불가능하기 때문에 모델과 데이터를 함께 발전시키는 데이터 엔진 방식을 채택

- 1단계(보조 수동 annotation): SAM이 어노테이터의 마스크 라벨링을 보조.
- 2단계(반자동): SAM이 일부 객체의 마스크를 자동으로 생성하고 어노테이터는 나머지 객체에 집중하여 마스크 다양성을 증가.
- 3단계(완전 자동): SAM에 격자형 전경 포인트를 프롬프트로 제공하여 이미지당 평균 약 100개의 고품질 마스크를 생성.

4-4. SA-1B 데이터셋

최종 데이터셋 SA-1B는 1,100만 장의 라이선스·프라이버시 보호 이미지에 10억 개 이상의 마스크를 포함함.

5. Experiments — 실험 구성과 결과

실험 구성: 23개의 다양한 세그멘테이션 데이터셋에서 zero-shot transfer 프로토콜로 평가

주요 실험 태스크

- 단일 포인트 기반 객체 세그멘테이션
- 엣지 검출
- 객체 후보 생성 (Object Proposal Generation)
- 인스턴스 세그멘테이션
- 텍스트-to-마스크 예측 (초기 탐색)

주요 결과

- SAM은 단일 전경 포인트로 고품질 마스크를 생성하며, 성능은 수동 어노테이션 정답에 단지 약간 못 미치는 수준
- 다양한 downstream 태스크에서 zero-shot transfer를 통해 일관되게 강력한 정량적/정성적 결과

마스크 품질 검증

- 전문 어노테이터가 500장 이미지(약 5만 개 마스크)를 검토한 결과, 94%의 마스크 쌍이 IoU 90% 이상을 달성함
→ 기존 연구에서 추정된 사람 간 일치도(85~91% IoU)를 상회하는 수준.

6. Discussion — 무엇을 발견했고 한계점은?

주요 발견

- Promptable 설계만으로 zero-shot 세그멘테이션이 기존 fully supervised 결과와 경쟁 가능
- 데이터 엔진 방식이 대규모 고품질 마스크 데이터 확보에 효과적
- 모델을 더 큰 시스템의 컴포넌트로 조합하는 방식이 유효함을 입증

한계점

- 의료 이미지에서 SAM의 zero-shot 성능은 평균적으로 중간 수준이며, 데이터셋과 태스크에 따라 크게 편차가 있음.
- 위장 객체, 투명 객체, 산업 결함 등 특수 도메인에서 성능 저하
- 텍스트 프롬프트 지원은 초기 탐색 수준에 머물러 있어 완성도가 낮음
- 프롬프트 없이는 원하는 객체를 정확히 지정하기 어려움

7. Conclusion

SAM 모델은 새로운 이미지 분포와 태스크에 zero-shot으로 전이하도록 설계, 학습됨. → 다양한 태스크에서의 zero-shot 성능은 매우 인상적임.

8. 기존 연구 대비 차별점

구분	기존 세그멘테이션 연구	SAM
학습 방식	특정 태스크·도메인에 특화	범용 promptable 사전학습
데이터 규모	수십만~수백만 마스크	10억 개 마스크 (SA-1B)

구분	기존 세그멘테이션 연구	SAM
추론 방식	고정 카테고리 분류	임의 프롬프트로 zero-shot 분할
데이터 수집	사람이 직접 어노테이션	모델+사람의 반복적 데이터 엔진
실시간성	대부분 느린 추론	~50ms (CPU 웹 브라우저)
모호성 처리	단일 출력	다중 마스크 + 신뢰도 점수

9. 핵심 아이디어

"Task + Model + Data를 동시에 새롭게 정의하여, 어떤 객체든 프롬프트 하나로 분할하는 세그멘테이션 foundation model을 만든다"