

학기 5주차 : TabNet & TabPFN

📅 날짜	2026년 4월 2일
☀️ 상태	완료

1. TabNet: Attentive Interpretable Tabular Learning

Sercan O. Arik, Tomas Pfister · Google Cloud AI · AAAI 2021

Abstract

테이블형 데이터는 가장 흔한 데이터 유형임에도 불구하고 딥러닝을 적용하면 오히려 성능이 떨어짐.

핵심 해결 과제

1. 해석 가능성 - 결정 트리처럼 어떤 피처가 예측에 기여했는지 설명할 수 있어야 함.
2. 성능 - 대규모 테이블 데이터에서 기존 트리 계열 모델을 능가해야 함.
- **Sequential Attention** 기반의 인스턴스별 피처 선택으로 해석 가능성과 성능을 동시에 달성하는 딥러닝 테이블 데이터 아키텍처 제안.

Introduction

왜 결정 트리가 지배적인가?

1. 하이퍼플레인 형태의 결정 경계에 표현 효율적
2. 기본 형태에서 해석 가능
3. 학습 속도 빠름. 반면 CNN·MLP 같은 기존 DNN은 적절한 귀납적 편향(inductive bias)이 없어 테이블 결정 매니폴드에서 최적해를 찾지 못함.

왜 딥러닝이 필요한가?

1. 대규모 데이터에서 성능 향상 기대
2. 이미지·텍스트 등 다른 모달리티와 엔드투엔드 통합
3. 피처 엔지니어링 불필요
4. 스트리밍 학습
5. 표현 학습 — 도메인 적응, 생성 모델, 반지도 학습 지원.

기존 DNN이 테이블 데이터에 실패하는 핵심 원인 - 인스턴스별 피처 선택 메커니즘의 부재.

Related Works

피처 선택 연구: Forward Selection, Lasso 정규화(전역 방법) → L2X(상호정보량 극대화), INVASE(액터-크리틱 프레임워크)로 인스턴스별 방법 발전. 그러나 이들은 별도의 설명 모델을 추가하는 이중 구조로 비효율적임.

트리 기반 학습: Random Forest, XGBoost, LightGBM이 대부분의 데이터 사이언스 대회를 지배. 분산 감소를 위한 앙상블이 핵심 전략이다.

DNN-DT 통합 시도: Soft(Neural) Decision Tree — 미분 가능한 결정 함수 사용, 그러나 자동 피처 선택 손실. NODE — 피처 조합의 명시적 활용이나 그래디언트 부스팅 지식 전이에 의존. 이 시도들은 모두 피처 선택과 추론을 분리하거나 외부 모델에 의존하는 한계.

자기지도 학습: BERT(텍스트), SimCLR(이미지)의 마스킹 기반 사전학습 성공에서 영감 → 테이블 데이터에는 아직 적용된 바 없음.

Method

핵심 설계 원칙 4가지

1. 데이터별 희소 인스턴스 피처 선택
2. 순차적 멀티스텝 아키텍처(각 스텝이 일부 결정에 기여)
3. 선택된 피처의 비선형 처리로 학습 용량 향상
4. 더 많은 차원과 스텝으로 앙상블 효과 모방.

어텐티브 트랜스포머(Attentive Transformer)

피처 트랜스포머: FC → BN → GLU 비선형성의 4층 구조. 일부는 모든 결정 스텝에서 공유, 일부는 스텝별 독립. 정규화된 잔차 연결($\sqrt{0.5}$)로 학습 안정성 확보함.

자기지도 사전학습(Self-Supervised Pre-training): 인코더-디코더 구조로 무작위로 마스킹된 피처를 복원하는 태스크를 수행. 레이블 없는 데이터가 많을 때 성능을 크게 향상시킴.

해석 가능성: 로컬 — 각 스텝의 마스크 $M[i]$ 가 해당 입력에서 어떤 피처가 중요한지 시각화. 글로벌 — 모든 스텝의 집계 마스크로 전체 모델의 피처 기여도 정량화.

Experiments

합성 데이터셋(Syn1~6): 인스턴스별 피처 선택 능력 검증. Syn4~6처럼 샘플에 따라 중요 피처가 달라지는 경우 전역 피처 선택 방법을 능가했으며, INVASE와 동등한 성능을 단일 26~31k 파라미터 모델로 달성(INVASE는 101k 파라미터의 세 모델 사용).

Forest Cover Type: XGBoost 89.34%, LightGBM 89.28%, AutoML Tables 94.95% 대비 TabNet 96.99% 달성. 정밀한 하이퍼파라미터 탐색 없이 AutoML Tables

를 증가함.

Poker Hand, Sarcos, Higgs Boson 등: 분류·회귀 다양한 도메인에서 XGBoost·LightGBM·CatBoost·MLP 대비 우수하거나 동등한 성능 달성. 자기지도 사전학습 적용 시 레이블 제한 환경에서 추가 성능 향상 확인.

Discussion

주요 발견: Sequential Attention이 실제로 의미 있는 피처 그룹을 자동으로 발견한다는 것을 실험적으로 확인. Adult Census Income 예측에서 스텝1은 직업 관련 피처에, 스텝2는 투자 관련 피처에 집중하는 행동을 보임.

한계점

1. 하이퍼파라미터(Nsteps, 마스크 희소성 λ_{sparse} , 배치 크기 등)에 대한 민감도가 일부 존재.
2. 매우 작은 데이터셋에서는 앙상블 트리 대비 여전히 열세일 수 있음.
3. 카테고리형 피처는 1차원 임베딩으로 처리해 복잡한 카테고리 관계 표현에 제약.
4. 테이블 특화 아키텍처이므로 다른 모달리티와의 유기적 통합은 추가 설계 필요.

Conclusion

TabNet은 테이블 데이터를 위한 첫 번째 캐노니컬 딥러닝 아키텍처로서, Sequential Attention을 통한 인스턴스별 피처 선택으로 높은 예측 성능, 로컬·글로벌 해석 가능성, 자기지도 사전학습 지원 세 가지를 동시에 달성함. 또한, 결정 트리의 장점인 피처 선택과 해석 가능성을 딥러닝의 표현 학습 능력과 결합한 최초의 시도임.

TabNet의 핵심 아이디어

Sequential Attention + Sparsemax = 인스턴스별 희소 피처 선택

각 결정 스텝에서 이전 스텝 정보를 바탕으로 이번 스텝에서 집중할 피처를 동적으로 선택. Sparsemax가 확률을 0으로 날카롭게 수렴시켜 실제로 희소한 선택이 이루어지고, Prior Scale이 이미 사용된 피처에 패널티를 부여해 각 스텝이 다양한 피처 그룹을 자동으로 분업함. 이 과정 자체가 해석 가능성의 시각적 증거가 됨.

2. TabPFN: Accurate predictions on small data with a tabular foundation model

Noah Hollmann et al. · University of Freiburg · Nature 2025

Abstract

생의학부터 입자물리학, 경제학, 기후과학까지 테이블 데이터는 모든 과학 분야에 편재해 있음. 그러나 지난 20년간 Gradient Boosted Decision Tree(XGBoost, LightGBM 등)가 이 영역을 지배해 왔고 딥러닝은 이를 넘어서지 못했습니다.

핵심 문제는 **소규모 데이터(~10,000 샘플)에서의 빠르고 정확한 예측이다**. 실제로 openml.org의 테이블 데이터셋 76%가 10,000행 미만이며, 각 도메인별로 특화된 작은 독립 데이터셋이 범람하고 있는 상황인데 예측이 잘 되지 않고 있음.

**** 수백만 개의 합성 데이터셋으로 사전학습된 Foundation Model이 단 2.8초 만에 4시간 동안 튜닝한 최강 앙상블 트리를 능가.**

Introduction

수작업으로 설계된 알고리즘은 항상 엔드투엔드 학습된 것으로 대체되어 옴.

⇒ 컴퓨터 비전의 SIFT·HOG → 학습된 컨볼루션, NLP의 문법 규칙 → 트랜스포머. 저자들은 이 패러다임을 테이블 데이터로 확장함.

기존 트리 계열 모델의 한계

1. 분포 외(OOD) 예측 성능 불량
2. 데이터셋 간 지식 전이 불가
3. 신경망과 통합 시 그라디언트 전파 불가
4. 각 데이터셋마다 수 시간의 하이퍼파라미터 탐색 필요.

딥러닝이 테이블에서 실패한 이유: 데이터셋 간 이질성(약물 발견 vs 소재과학은 완전히 다른 의미의 값), 원시 데이터의 이질성(Boolean, 범주형, 순서형, 정수, 부동소수점 혼재), 결측값, 이상치, 불균형 데이터 등

Related Works

In-Context Learning(ICL): GPT-3의 few-shot learning에서 처음 관찰. 이후 트랜스포머가 ICL을 통해 로지스틱 회귀 등 간단한 알고리즘을 학습할 수 있음이 밝혀짐.

PFN(Prior-data Fitted Networks) 이론이 트랜스포머로 가우시안 프로세스와 베이지안 신경망을 근사할 수 있음을 보임.

테이블 딥러닝 시도: TabNet(어텐션 기반 피쳐 선택), FT-Transformer, NODE, SAINT 등이 제안되었으나 여전히 트리 계열 대비 일관된 우위 불가. 특히 소규모 데이터에서 격차가 큼.

Foundation Model 관점: NLP의 BERT·GPT, 비전의 CLIP처럼 크로스-도메인 사전학습 후 파인튜닝하는 패러다임이 테이블 데이터에는 미적용 상태. XTab, SAINT 등이 크로스-테이블 사전학습을 시도했으나 실제 데이터로의 전이에 한계.

Method

3단계 파이프라인

1. **합성 데이터 생성(Prior):** 인과 모델(Structural Causal Models)을 사용해 다양한 피처-타겟 관계를 가진 수백만 개의 합성 테이블 데이터셋 생성. 결측값, 이상치, 불필요한 피처 등을 포함한 현실적 챌린지를 합성 데이터에 내재화함.
2. **PFN 사전학습(Pre-training):** 트랜스포머 모델을 이 합성 데이터셋들로 학습. 각 데이터셋에서 일부 샘플의 레이블을 마스킹하고, 나머지 샘플을 컨텍스트로 제공해 마스킹된 레이블을 예측하도록 훈련. 이 과정은 단 한 번만 수행됨.
3. **실세계 추론(Inference via ICL):** 학습된 모델에 실세계 훈련 샘플을 컨텍스트로 입력하면, 단 하나의 Forward Pass로 테스트 샘플의 레이블을 예측. 추가 학습(weight update) 없음.

테이블 특화 아키텍처: 표준 트랜스포머를 테이블 구조에 맞게 수정. 각 셀(행×열)에 별도 표현 할당, 행(샘플 내 피처 간)과 열(동일 피처의 샘플 간) 두 방향의 어텐션 적용. 샘플 순서와 피처 순서에 불변함.

이론적 기반: Bayesian 예측의 근사로 해석 가능. 합성 데이터 Prior에 기반한 사후 예측 분포 $p(y_{\text{test}} \mid X_{\text{test}}, X_{\text{train}}, y_{\text{train}})$ 를 근사함.

Experiments

분류 벤치마크: 10,000 샘플 이하 데이터셋에서 XGBoost, LightGBM, CatBoost 등 최강 앙상블 트리(4시간 튜닝)를 **2.8초** 만에 능가. 속도 개선 5,140배.

회귀 벤치마크: 동일 조건에서 앙상블 트리(4시간 튜닝) 대비 우수한 성능. 속도 개선 3,000배.

파운데이션 모델 특성 실증: 파인튜닝(도메인 적응), 데이터 생성(합성 데이터 생성), 밀도 추정(density estimation), 재사용 가능 임베딩 추출 등 GPT·BERT와 같은 파운데이션 모델 특성을 테이블 데이터에서 최초로 실증.

한계 실험: 10,000 샘플 초과 데이터셋에서는 성능 우위가 줄어들거나 역전되는 현상 확인. 500 피처 초과 시에도 성능 저하 경향.

Discussion

실제 데이터를 전혀 보지 않고 합성 데이터로만 학습한 모델이 해당 데이터로 수 시간 튜닝된 최강 모델을 능가한다는 것은 "학습 알고리즘 자체를 학습"하는 메타러닝 패러다임의 강력함을 입증함.

합성 Prior 설계의 중요성: 실세계 데이터 분포를 얼마나 잘 모사하는 Prior를 설계하느냐가 성능의 핵심 병목. 인과 모델 기반 합성이 이를 효과적으로 해결함.

한계점

1. 10,000 샘플 초과 대규모 데이터셋에서는 기존 트리 계열 대비 우위 불분명

2. 500개 이상의 피처에서 성능 저하
3. Forward Pass 시 전체 훈련 세트를 컨텍스트로 입력해야 하므로 메모리 사용량이 데이터셋 크기에 비례
4. 합성 Prior의 한계 — 실세계 데이터의 모든 복잡성을 포착하지 못할 수 있음
5. 예측 이유에 대한 해석 가능성은 TabNet 대비 약함.

Conclusion

TabPFN은 테이블 데이터를 위한 최초의 실용적 파운데이션 모델로서, "학습 알고리즘을 학습한다"는 메타러닝 철학을 테이블 도메인에 성공적으로 적용했음. 소규모 테이블 데이터에서 기존 최고 모델을 압도적 속도로 능가하며, 파인튜닝·생성·밀도 추정·임베딩 등 파운데이션 모델의 다양한 특성을 실증해 테이블 AI의 새로운 패러다임을 제시!